

Integração de Lógica Fuzzy e Modelagem de Dependência em Risco de Crédito Estruturado

Matheus de Azevedo Nascimento, Breno Fernando Pereira Molon, Marina Laís Rosa

ABSTRACT

Risk modeling in structured credit instruments depends heavily on the representation of dependence among default events and on the proper characterization of the variables that compose credit risk. Although copula-based models have become standard tools for representing statistical dependence among defaults, key parameters such as Probability of Default (PD) and Loss Given Default (LGD) often involve significant epistemic uncertainty arising from limited data availability and expert judgment requirements. In this context, this study proposes an integrated framework combining copula-based dependence modeling and Mamdani-type fuzzy logic to explicitly represent the imprecision associated with credit risk parameters. The proposed methodology includes the definition of membership functions for PD and LGD, the construction of a fuzzy rule base obtained through a knowledge elicitation process involving a human expert and large language models, and the implementation of an inference system capable of generating a composite risk index. At the current stage, the results are preliminary and focus on the comparative analysis of the rules proposed by the different knowledge sources, highlighting regions of agreement and disagreement in risk classification. Future work will incorporate expert assessments and computational implementation of the model in order to evaluate the potential of fuzzy logic as a complementary tool to traditional probabilistic approaches in structured credit risk modeling.

Keywords: Credit Risk; Fuzzy Logic; Mamdani Inference System; Probability of Default; Loss Given Default; Copulas; Epistemic Uncertainty.

RESUMO

A modelagem de risco em estruturas de crédito securitizado depende fortemente da representação da dependência entre eventos de inadimplência e da caracterização adequada das variáveis que compõem o risco de crédito. Embora modelos baseados em cópulas tenham se consolidado como ferramentas para representar dependência estatística entre *defaults*, parâmetros fundamentais como *Probability of Default* (PD) e *Loss Given Default* (LGD) frequentemente apresentam incerteza epistemológica decorrente da limitação de dados e da necessidade de julgamento especializado. Nesse contexto, este trabalho propõe uma abordagem integrada que combina modelagem de dependência por cópulas e lógica *fuzzy* do tipo Mamdani para representar explicitamente a imprecisão associada aos parâmetros de risco. A metodologia contempla a definição de funções de pertinência para PD e LGD, a construção de uma base de regras *fuzzy* obtida por meio de um processo de elicitação de conhecimento envolvendo um especialista humano e modelos de linguagem de grande porte, bem como a implementação de um sistema de inferência capaz de gerar um índice composto de risco. Os resultados apresentados neste estágio são preliminares e concentram-se na análise comparativa das regras propostas pelas diferentes fontes de conhecimento, permitindo identificar regiões de consenso e divergência na classificação do risco. Espera-se que a incorporação do julgamento do especialista humano e a posterior implementação computacional do modelo possibilitem avaliar o potencial da lógica *fuzzy* como ferramenta complementar à modelagem probabilística tradicional em aplicações de risco de crédito estruturado.

Palavras-chave: Risco de Crédito; Lógica Fuzzy; Sistema Mamdani; Probability of Default; Loss Given Default; Cópulas; Incerteza Epistemológica.

1. INTRODUÇÃO

A crise financeira global de 2008 evidenciou limitações relevantes nos modelos utilizados para avaliação e gerenciamento de risco em instrumentos de crédito estruturado. Entre os diversos fatores apontados pela literatura para explicar a magnitude das perdas observadas, destacam-se as dificuldades associadas à modelagem da dependência entre eventos de inadimplência e à estimação dos parâmetros que alimentam esses modelos. Embora avanços significativos tenham sido alcançados por meio da utilização de cópulas para representar a estrutura de dependência entre ativos, a crise demonstrou que parte das incertezas presentes no processo de modelagem permanece pouco explorada.

Grande parte dos modelos empregados em finanças quantitativas assume que variáveis como *Probability of Default* (PD) e *Loss Given Default* (LGD) podem ser representadas por valores pontuais. Na prática, entretanto, esses parâmetros são frequentemente estimados a partir de séries históricas limitadas, informações incompletas e julgamentos especializados. Como consequência, existe uma parcela de incerteza associada não apenas ao comportamento futuro dos ativos, mas também à própria definição dos parâmetros utilizados para representá-los.

A literatura de risco distingue essa situação da incerteza aleatória tradicional. Enquanto a ocorrência de um evento de inadimplência está sujeita à variabilidade inerente dos fenômenos econômicos, a determinação da probabilidade desse evento e da severidade das perdas envolve elementos de natureza epistemológica, decorrentes de limitações de conhecimento, disponibilidade de dados e interpretação dos analistas. Em cenários de elevada complexidade, diferentes especialistas podem chegar a classificações distintas para uma mesma situação de risco, mesmo quando possuem acesso às mesmas informações.

A lógica *fuzzy*, proposta por Zadeh [1], oferece uma alternativa para representar esse tipo de imprecisão. Diferentemente das abordagens probabilísticas convencionais, que buscam quantificar a chance de ocorrência de eventos, a lógica *fuzzy* permite modelar conceitos graduais e categorias linguísticas, incorporando explicitamente regiões de transição entre classificações como baixo, moderado, alto e crítico. Essa característica torna a abordagem particularmente atrativa para problemas nos quais o conhecimento especializado desempenha papel relevante na tomada de decisão.

Apesar da ampla utilização da lógica *fuzzy* em problemas de classificação e apoio à decisão, sua aplicação à modelagem de risco de crédito estruturado permanece limitada quando comparada às abordagens probabilísticas tradicionais. Em especial, observa-se uma escassez de estudos que investiguem como o conhecimento de especialistas pode ser formalizado por meio de sistemas de inferência *fuzzy* e integrado ao processo de avaliação de risco.

Diante desse cenário, este trabalho propõe uma estrutura conceitual baseada em lógica *fuzzy* do tipo *Mamdani* para representar a interação entre *Probability of Default* e *Loss Given Default* na construção de um índice composto de risco. A base de regras do sistema é obtida por meio de um processo de elicitación de conhecimento envolvendo diferentes fontes independentes, incluindo um especialista humano e modelos de linguagem de grande porte. A comparação entre essas fontes permite analisar regiões de convergência e divergência na classificação do risco, contribuindo para uma discussão mais ampla sobre subjetividade, incerteza e transparência na modelagem de crédito.

O objetivo do estudo é investigar o potencial da lógica *fuzzy* como ferramenta complementar às abordagens probabilísticas tradicionais, fornecendo um mecanismo estruturado

para representar a imprecisão presente na definição dos parâmetros de risco e no julgamento especializado utilizado em processos de tomada de decisão financeira.

2. REVISÃO DE LITERATURA

2.1. Modelagem de Dependência em Risco de Crédito

A modelagem da dependência entre eventos de inadimplência constitui um dos principais desafios na avaliação de risco de crédito, especialmente em estruturas securitizadas compostas por grande quantidade de ativos. Diferentemente de operações individuais, nas quais a perda está associada ao comportamento de um único tomador, instrumentos como *Collateralized Debt Obligations* (CDOs) e carteiras diversificadas dependem fortemente da ocorrência simultânea de múltiplos eventos de *default*. Nessas situações, a forma como a dependência é representada pode exercer influência significativa sobre as estimativas de perda e sobre a mensuração do risco de cauda.

O desenvolvimento moderno dessa área foi impulsionado pelo Teorema de Sklar [2], segundo o qual qualquer distribuição conjunta pode ser decomposta em distribuições marginais individuais e em uma função responsável por descrever a estrutura de dependência existente entre as variáveis. Essa formulação permitiu separar a modelagem das probabilidades individuais de inadimplência da modelagem da relação entre os eventos de *default*, criando uma base matemática para o desenvolvimento das cópulas.

A aplicação dessa abordagem ao risco de crédito ganhou destaque com o trabalho de Li [3], que propôs a utilização da cópula Gaussiana para modelar a dependência entre tempos de inadimplência. A simplicidade matemática do modelo e a facilidade de calibração contribuíram para sua ampla adoção pelo mercado financeiro durante os anos que antecederam a crise financeira global de 2008. A metodologia passou a ser utilizada na precificação de instrumentos estruturados e na avaliação de risco de portfólios complexos, tornando-se uma referência para instituições financeiras e agências de classificação de risco.

Apesar de sua popularidade, a literatura especializada identificou limitações importantes associadas ao uso da cópula Gaussiana. Estudos desenvolvidos por Embrechts et al. [4] demonstram que a correlação linear não é suficiente para descrever adequadamente a dependência entre variáveis financeiras em situações extremas. Em particular, a cópula Gaussiana apresenta dependência de cauda nula, característica que tende a subestimar a probabilidade de ocorrência conjunta de eventos severos.

A relevância dessa limitação tornou-se evidente durante a crise de 2008, quando a deterioração simultânea de diversos ativos gerou perdas muito superiores às previstas pelos modelos tradicionais. Das et al. [5] observam que eventos de inadimplência apresentam comportamento agrupado ao longo do tempo, especialmente em períodos de estresse econômico, sugerindo que a dependência entre os ativos não permanece constante e pode se intensificar justamente nos cenários de maior interesse para a gestão de risco.

Como alternativa, diferentes extensões foram propostas na literatura. Entre elas destacam-se a cópula *t-Student*, capaz de representar dependência de cauda, e as estruturas baseadas em *vine copulas*, que permitem maior flexibilidade na modelagem de dependências complexas entre múltiplas variáveis [6], [7]. Embora essas abordagens representem avanços significativos, a estimação de seus parâmetros continua limitada pela disponibilidade de dados, particularmente

quando se trata de eventos raros e extremos.

Essa dificuldade está diretamente relacionada ao chamado risco de modelo. Conforme argumenta Cont [8], diferentes especificações podem produzir resultados substancialmente distintos mesmo quando calibradas com o mesmo conjunto de dados. Em consequência, a modelagem de dependência não depende exclusivamente da evidência empírica disponível, mas também das hipóteses adotadas pelo analista durante o processo de construção do modelo.

Diante dessas limitações, documentos do *Basel Committee on Banking Supervision* reconhecem a importância do julgamento especializado na avaliação de risco, especialmente em situações caracterizadas por escassez de dados ou elevada incerteza [9], [10]. Esse aspecto sugere que parte do processo de modelagem não está associada apenas à variabilidade estatística dos fenômenos observados, mas também à imprecisão presente na definição dos próprios parâmetros utilizados. É justamente nesse ponto que abordagens baseadas em lógica *fuzzy* podem contribuir, oferecendo mecanismos para representar explicitamente essa dimensão da incerteza.

2.2. Lógica Fuzzy e Representação da Imprecisão

A lógica *fuzzy* foi proposta por Zadeh [1] como uma extensão da lógica clássica para situações em que os limites entre categorias não podem ser definidos de forma precisa. Enquanto a lógica tradicional admite apenas pertencimento ou não pertencimento a um conjunto, a lógica *fuzzy* permite que um elemento apresente diferentes graus de pertencimento, representados por valores contínuos no intervalo entre zero e um.

Essa característica possibilita a representação matemática de conceitos naturalmente graduais, como alto risco, boa qualidade de crédito ou elevada severidade de perda. Em muitos problemas reais, essas classificações não possuem fronteiras claramente definidas, sendo influenciadas por fatores subjetivos e pela interpretação dos especialistas envolvidos na análise.

Formalmente, um conjunto *fuzzy* é definido por uma função de pertinência $\mu_A(x)$, responsável por associar cada elemento x a um grau de pertencimento pertencente ao intervalo $[0, 1]$. Quanto mais próximo de um, maior é a compatibilidade do elemento com a categoria representada. Diferentemente das abordagens probabilísticas, esse valor não representa a probabilidade de ocorrência de um evento, mas sim o grau com que determinado elemento satisfaz uma característica ou conceito.

A distinção entre probabilidade e lógica *fuzzy* é fundamental para a correta interpretação da metodologia proposta neste trabalho. A teoria da probabilidade busca quantificar a incerteza associada à ocorrência de eventos futuros. A lógica *fuzzy*, por sua vez, procura representar a imprecisão existente na definição de categorias e conceitos. Assim, enquanto a probabilidade responde à pergunta “qual a chance de um evento ocorrer?”, a lógica *fuzzy* busca responder “em que grau um determinado elemento pode ser considerado pertencente a uma categoria?”.

Ao longo das últimas décadas, diversos autores contribuíram para a consolidação da teoria *fuzzy* e para sua aplicação em problemas de decisão [11], [12]. Entre esses desenvolvimentos destaca-se o conceito de α -cut, que permite converter conjuntos *fuzzy* em intervalos clássicos para diferentes níveis de confiança. Essa propriedade torna possível integrar representações *fuzzy* a métodos quantitativos tradicionais, preservando a interpretação linguística original.

Outra contribuição importante foi apresentada por Bellman e Zadeh [13], que propuseram a utilização de conjuntos *fuzzy* em problemas de tomada de decisão. Nessa abordagem, objetivos e restrições podem ser representados por conjuntos *fuzzy*, permitindo que decisões

sejam avaliadas considerando simultaneamente diferentes graus de satisfação. Essa estrutura tornou-se a base para diversos sistemas especialistas desenvolvidos posteriormente.

No contexto do risco de crédito, a utilização da lógica *fuzzy* apresenta especial relevância devido à natureza das variáveis envolvidas. Parâmetros como *Probability of Default* (PD) e *Loss Given Default* (LGD) são frequentemente tratados como valores precisos nos modelos tradicionais [14]. Entretanto, sua determinação depende de informações históricas limitadas, hipóteses de modelagem e avaliações especializadas. Como consequência, diferentes analistas podem atribuir interpretações distintas a uma mesma situação de risco, mesmo quando utilizam os mesmos dados de entrada.

Uma forma amplamente utilizada para representar essa imprecisão consiste na adoção de números *fuzzy* triangulares ou trapezoidais. Esses números permitem descrever um intervalo de valores plausíveis, acompanhado de um grau de pertinência associado a cada ponto do intervalo. Dessa forma, o modelo deixa de representar PD e LGD como parâmetros pontuais e passa a incorporá-los como grandezas sujeitas à incerteza epistemológica.

Apesar de suas vantagens, a lógica *fuzzy* também apresenta limitações. A definição das funções de pertinência depende do conhecimento do especialista e das hipóteses adotadas durante a modelagem. Além disso, a metodologia não produz distribuições de probabilidade no sentido clássico, exigindo procedimentos complementares quando se deseja integrá-la a métricas financeiras tradicionalmente baseadas em distribuições estatísticas [15], [16].

Ainda assim, a principal contribuição da lógica *fuzzy* não está necessariamente no aumento da capacidade preditiva dos modelos, mas na possibilidade de representar explicitamente a imprecisão presente nos processos de avaliação. Em vez de ocultar a subjetividade por trás de valores aparentemente exatos, a abordagem *fuzzy* torna essa incerteza visível e passível de análise, contribuindo para maior transparência na construção dos modelos de risco.

2.3. Incerteza Epistêmica vs. Aleatória em Risco de Crédito

A modelagem de risco emoldura diferentes formas de incerteza que nem sempre podem ser tratadas adequadamente por uma única abordagem metodológica. Em aplicações financeiras, a teoria da probabilidade é tradicionalmente utilizada para representar a variabilidade inerente aos fenômenos observados, enquanto a lógica *fuzzy* oferece mecanismos para descrever situações caracterizadas por imprecisão conceitual ou insuficiência de conhecimento.

No contexto do risco de crédito, essas duas dimensões coexistem. A ocorrência de um evento de inadimplência possui natureza probabilística, uma vez que está associada a eventos futuros incertos [17]. Por outro lado, a definição dos parâmetros utilizados para representar esse risco frequentemente envolve julgamentos subjetivos, interpretações qualitativas e limitações de dados históricos. Assim, embora a probabilidade seja adequada para modelar a ocorrência dos eventos, ela não necessariamente captura a incerteza existente na própria definição dos parâmetros utilizados pelo modelo.

Essa distinção é particularmente relevante na análise de variáveis como *Probability of Default* (PD) e *Loss Given Default* (LGD). Em modelos convencionais, essas grandezas são representadas por valores pontuais estimados a partir de dados históricos ou procedimentos estatísticos. Entretanto, tais estimativas frequentemente carregam um grau significativo de imprecisão decorrente de fatores como mudanças de cenário econômico, limitações amostrais e divergências entre especialistas. Consequentemente, a representação desses parâmetros por va-

lores únicos pode transmitir uma percepção de precisão superior àquela efetivamente disponível.

Sob essa perspectiva, a lógica *fuzzy* e a modelagem probabilística podem ser compreendidas como abordagens complementares. Enquanto as cópulas e demais modelos probabilísticos descrevem a dependência estatística entre eventos de inadimplência, a lógica *fuzzy* permite representar a incerteza associada à classificação e à interpretação dos parâmetros que alimentam esses modelos. Em outras palavras, a modelagem probabilística procura responder como os eventos se relacionam, enquanto a lógica *fuzzy* auxilia na representação do grau de confiança atribuído aos parâmetros utilizados para descrever esses eventos.

A literatura reconhece que decisões relacionadas à gestão de risco frequentemente incorporam conhecimento especializado que não pode ser integralmente traduzido em distribuições de probabilidade. Em situações nas quais existem informações qualitativas relevantes, sistemas *fuzzy* permitem formalizar esse conhecimento por meio de regras linguísticas estruturadas. Essa característica é particularmente útil quando se busca incorporar experiência profissional, percepção de mercado e julgamentos especializados ao processo de modelagem.

Nesse sentido, a utilização de um sistema de inferência *fuzzy* do tipo *Mamdani* apresenta uma alternativa para integrar informações quantitativas e qualitativas em uma única estrutura analítica. Por meio de regras construídas a partir da combinação entre diferentes níveis de PD e LGD, torna-se possível gerar uma avaliação composta de risco que preserve a interpretação linguística utilizada pelos especialistas e, simultaneamente, mantenha consistência lógica entre as classificações produzidas.

É importante destacar que a incorporação da lógica *fuzzy* não elimina as limitações associadas à disponibilidade de dados nem substitui a modelagem probabilística tradicional. Seu principal papel consiste em tornar explícita a imprecisão presente na construção dos parâmetros e na formulação dos julgamentos utilizados durante a análise. Dessa forma, a abordagem proposta neste trabalho deve ser interpretada como um mecanismo complementar de representação da incerteza, contribuindo para ampliar a transparência e a rastreabilidade do processo de avaliação de risco.

Com base nessa integração conceitual, a próxima seção apresenta o sistema de inferência *fuzzy* adotado neste estudo e o procedimento utilizado para construção da base de regras que relaciona *Probability of Default*, *Loss Given Default* e o índice composto de risco.

2.4. Sistema de Inferência Fuzzy do Tipo Mamdani

Os sistemas de inferência *fuzzy* constituem uma das aplicações mais difundidas da lógica *fuzzy* em problemas de apoio à decisão. Entre as diferentes abordagens existentes, o modelo proposto por Mamdani e Assilian [18] destaca-se pela capacidade de representar conhecimento especializado por meio de regras linguísticas de fácil interpretação, tornando-se amplamente utilizado em aplicações de engenharia, gestão de risco e sistemas especialistas.

A estrutura de um sistema *Mamdani* é composta por quatro etapas principais: fuzzificação, avaliação das regras, agregação dos resultados e defuzzificação. Essas etapas permitem transformar informações de entrada em uma saída numérica ou categórica, preservando o raciocínio linguístico utilizado pelos especialistas durante o processo de tomada de decisão.

A primeira etapa corresponde à fuzzificação. Nessa fase, valores numéricos das variáveis de entrada são convertidos em graus de pertencimento associados a conjuntos *fuzzy* previamente definidos. No contexto deste trabalho, as variáveis *Probability of Default* (PD) e *Loss*

Given Default (LGD) são representadas por categorias linguísticas como Baixo, Moderado, Alto e Crítico. Cada valor observado passa a possuir diferentes graus de pertencimento a essas categorias, permitindo representar situações intermediárias que dificilmente seriam capturadas por classificações rígidas.

Após a fuzzificação, ocorre a avaliação da base de regras. As regras *fuzzy* são normalmente expressas na forma condicional clássica:

SE condição ENTÃO consequência

Por exemplo, uma regra pode estabelecer que:

SE PD é Alto E LGD é Alto, ENTÃO o risco é Crítico.

Esse tipo de representação aproxima a modelagem computacional da forma como especialistas costumam descrever processos de avaliação de risco. Em vez de depender exclusivamente de equações matemáticas, o conhecimento pode ser formalizado por meio de sentenças linguísticas compreensíveis e auditáveis.

Na etapa seguinte, denominada agregação, os resultados produzidos pelas diferentes regras são combinados para formar uma única função de pertencimento de saída. Como múltiplas regras podem ser ativadas simultaneamente para uma mesma combinação de entradas, a agregação permite considerar todas as evidências produzidas pelo sistema antes da geração do resultado.

Por fim, realiza-se a defuzzificação. Esse procedimento converte o conjunto *fuzzy* de saída em um valor único, possibilitando a interpretação quantitativa do resultado. Entre os diversos métodos disponíveis, o método do centroide é um dos mais utilizados por produzir respostas estáveis e coerentes com a distribuição dos graus de segurança. Nesse método, o resultado corresponde ao centro de gravidade da função de pertinência agregada.

A escolha do sistema *Mamdani* para este estudo está associada principalmente à sua interpretabilidade. Diferentemente de modelos mais orientados à otimização matemática, como os sistemas de Sugeno, o método *Mamdani* preserva explicitamente as regras linguísticas utilizadas durante a construção do modelo. Essa característica facilita a análise crítica das decisões produzidas, permite rastrear a origem das classificações e favorece a participação de especialistas no processo de modelagem.

Outro aspecto relevante é a compatibilidade do método com procedimentos de eliciação de conhecimento. Como as regras podem ser definidas diretamente por especialistas, torna-se possível comparar diferentes percepções sobre o problema e investigar regiões de convergência ou divergência na classificação do risco. Essa capacidade é particularmente importante para o presente estudo, cuja proposta envolve a construção e validação de uma base de regras obtida a partir de múltiplas fontes de conhecimento.

Dessa forma, o sistema de inferência *Mamdani* fornece o mecanismo responsável por transformar as avaliações linguísticas associadas a *Probability of Default* e *Loss Given Default* em um índice composto de risco, constituindo o núcleo analítico da abordagem proposta neste trabalho.

3. METODOLOGIA


3.1. Delineamento da Pesquisa

Este trabalho caracteriza-se como uma pesquisa aplicada, de natureza exploratória e abordagem predominantemente quantitativa. O estudo foi desenvolvido com o objetivo de investigar a utilização da lógica *fuzzy* como ferramenta complementar à modelagem tradicional de risco de crédito, buscando representar explicitamente a incerteza presente na definição de parâmetros utilizados em processos de avaliação financeira.

A motivação da pesquisa decorre da constatação de que variáveis amplamente empregadas em modelos de risco, como *Probability of Default* (PD) e *Loss Given Default* (LGD), frequentemente dependem de informações incompletas e de julgamentos especializados. Embora membros da academia apontem que os métodos probabilísticos sejam adequados para representar a ocorrência de eventos aleatórios, parte da incerteza presente nesses parâmetros está relacionada à interpretação dos dados disponíveis e à percepção dos especialistas responsáveis pela análise.

Diante desse cenário, foi proposta uma estrutura baseada em lógica *fuzzy* do tipo *Mamdani* para representar a interação entre PD e LGD na construção de um Índice de Risco Composto (IRC). A escolha dessa abordagem fundamenta-se na capacidade dos sistemas *fuzzy* de incorporar conhecimento linguístico e representar gradualmente conceitos que não possuem fronteiras claramente definidas.

O desenvolvimento do estudo foi organizado em quatro etapas principais. A primeira consistiu na revisão bibliográfica sobre modelagem de dependência em risco de crédito, teoria dos conjuntos *fuzzy* e sistemas de inferência do tipo *Mamdani*. A segunda etapa envolveu a definição das variáveis de entrada e das respectivas categorias linguísticas utilizadas no modelo. Na terceira etapa foi realizado o processo de eliciação de conhecimento, buscando obter classificações de risco para diferentes combinações de PD e LGD a partir de múltiplas fontes independentes. Por fim, a quarta etapa contemplou a comparação entre as classificações obtidas, a definição da base final de regras *fuzzy* e sua preparação para futura implementação computacional. A Figura 1 apresenta uma visão geral das etapas que compõem a metodologia adotada neste estudo.

Figura 1. Fluxograma da metodologia adotada no estudo

Fonte: Elaborado pelos autores (2026).

3.2. Variáveis do Modelo

3.2.1. *Probability of Default (PD)*

A *Probability of Default* (PD) representa a probabilidade de que uma operação de crédito, ativo financeiro ou contraparte entre em situação de inadimplência durante um horizonte temporal previamente definido.

A PD constitui uma das principais métricas utilizadas em modelos de risco de crédito e está diretamente associada à frequência esperada de ocorrência de perdas. Em termos conceituais, valores mais elevados de PD indicam maior probabilidade de classificação descendente ou deterioração da qualidade creditícia do ativo analisado. Para fins de construção do sistema *fuzzy*, a variável foi dividida em quatro categorias linguísticas:

- Baixo;
- Moderado;
- Alto;
- Crítico.

Essas categorias permitem representar diferentes níveis de risco percebido sem a necessidade de estabelecer limites rígidos entre classes adjacentes.

3.2.2. *Loss Given Default (LGD)*

A *Loss Given Default* (LGD) corresponde à proporção da exposição financeira que se espera perder após a ocorrência de um evento de inadimplência.

Essa variável está associada à severidade da perda e depende de fatores como garantias disponíveis, capacidade de recuperação dos ativos, condições de mercado e eficiência dos processos de cobrança. Mesmo quando duas operações apresentam probabilidades semelhantes de inadimplência, diferenças significativas na LGD podem resultar em níveis de risco substancialmente distintos.

Assim como a PD, a LGD foi representada por quatro categorias linguísticas:

- Baixo;
- Moderado;
- Alto;
- Crítico.

A utilização dessas categorias permite incorporar avaliações qualitativas frequentemente utilizadas por especialistas durante processos de análise de risco.

3.2.3. Índice de Risco Composto (IRC)

O Índice de Risco Composto (IRC) constitui a variável de saída do sistema de inferência *fuzzy*. Seu objetivo é finalizar e sintetizar, em uma única classificação, o efeito conjunto da *Probability of Default* e da *Loss Given Default*.

A interpretação do IRC segue a mesma estrutura linguística adotada para as variáveis de entrada, sendo composto pelas categorias:

- Baixo;
- Moderado;
- Alto;
- Crítico.

A utilização de uma escala comum para entrada e saída facilita a interpretação dos resultados e torna mais intuitiva a construção das regras *fuzzy* utilizadas pelo sistema *Mamdani*.

3.2.4. Estrutura Linguística das Variáveis

A Tabela 1 apresenta as variáveis consideradas no modelo e suas respectivas categorias linguísticas.

Tabela 1. Variáveis utilizadas no sistema de inferência *fuzzy*

Variável	Descrição	Categorias Linguísticas
PD	<i>Probability of Default</i>	Baixo, Moderado, Alto, Crítico
LGD	<i>Loss Given Default</i>	Baixo, Moderado, Alto, Crítico
IRC	Índice de Risco Composto	Baixo, Moderado, Alto, Crítico

Fonte: Elaborado pelos autores (2026).

A adoção dessas categorias foi motivada pela necessidade de construir uma estrutura simples, interpretável e compatível com o processo de elicitación de conhecimento realizado neste estudo. A utilização de quatro níveis de classificação permite representar diferentes intensidades de risco sem tornar a base de regras excessivamente complexa.

3.3. Construção das Funções de Pertinência

A representação das variáveis linguísticas em sistemas *fuzzy* exige a definição de funções de pertinência capazes de associar valores numéricos a diferentes categorias de classificação. Essas funções constituem o mecanismo responsável por converter informações quantitativas em graus de pertencimento, permitindo que o sistema opere sobre conceitos linguísticos em vez de limites rígidos de classificação.

Neste estudo, as variáveis *Probability of Default* (PD), *Loss Given Default* (LGD) e Índice de Risco Composto (IRC) foram representadas por meio de conjuntos *fuzzy* definidos sobre quatro categorias linguísticas: Baixo, Moderado, Alto e Crítico. A escolha dessas categorias foi realizada com o objetivo de preservar a simplicidade interpretativa do modelo, mantendo compatibilidade com a linguagem normalmente utilizada por especialistas em risco de crédito.

Para a modelagem das funções de pertinência foram adotadas funções triangulares, amplamente utilizadas na literatura devido à sua simplicidade matemática, facilidade de implementação e interpretação intuitiva. Cada categoria linguística é representada por três parâmetros que definem os limites inferior, modal e superior do conjunto *fuzzy* correspondente.

A utilização de funções triangulares permite que uma mesma observação apresente pertencimento simultâneo a categorias adjacentes. Essa característica é particularmente importante em problemas de classificação de risco, nos quais frequentemente não existem fronteiras claramente definidas entre diferentes níveis de criticidade.

A definição dos parâmetros das funções de pertinência foi realizada com base em revisão bibliográfica especializada e será posteriormente refinada a partir das contribuições obtidas durante o processo de elicitación de conhecimento. Essa estratégia busca garantir que as funções adotadas reflitam não apenas aspectos teóricos presentes na literatura, mas também a percepção prática dos especialistas envolvidos na análise.

As funções de pertinência do Índice de Risco Composto seguem a mesma estrutura linguística utilizada para as variáveis de entrada. Dessa forma, o resultado produzido pelo sistema *Mamdani* permanece consistente com as categorias empregadas durante a avaliação das combinações entre PD e LGD, facilitando a interpretação dos resultados gerados pelo modelo.

Após a definição das funções de pertinência, a etapa seguinte consiste na construção da base de regras *fuzzy* que descreve como as combinações entre *Probability of Default* e *Loss Given Default* influenciam a classificação final do risco. Esse procedimento é apresentado na seção seguinte.

3.4. Procedimento de Elicitación de Conhecimento

A construção da base de regras utilizada no sistema de inferência *fuzzy* constitui uma das etapas centrais deste estudo. Diferentemente de modelos puramente estatísticos, nos quais as relações entre variáveis são obtidas exclusivamente a partir de dados observados, sistemas *fuzzy* dependem da formalização de conhecimento especializado por meio de regras linguísticas

que descrevem o comportamento do fenômeno analisado.

Com o objetivo de reduzir a influência de vieses individuais e ampliar a robustez da base de regras, foi adotado um procedimento de elicitación de conhecimento envolvendo múltiplas fontes independentes. O processo contemplou a participação de um especialista humano com conhecimento em risco de crédito, bem como dois modelos de linguagem de grande porte (*Large Language Models* – LLMs), denominados ChatGPT e Claude.

A utilização de diferentes fontes de conhecimento não teve como finalidade substituir a avaliação humana ou atribuir autoridade técnica aos modelos de linguagem. O propósito foi investigar o grau de convergência e divergência existente entre diferentes agentes quando confrontados com o mesmo problema de classificação de risco. Considerando que a avaliação de variáveis como *Probability of Default* (PD) e *Loss Given Default* (LGD) envolve elementos de subjetividade, espera-se que diferenças de interpretação possam surgir mesmo diante de cenários idênticos.

Para garantir consistência metodológica, todas as fontes receberam exatamente o mesmo conjunto de instruções, definições e categorias linguísticas. O problema proposto consistiu na classificação do Índice de Risco Composto (IRC) para cada combinação possível entre os níveis de PD e LGD. Foram consideradas quatro categorias linguísticas para cada variável: Baixo, Moderado, Alto e Crítico.

A combinação dessas categorias resultou em uma matriz de dezesseis cenários possíveis, conforme apresentado na Tabela 2.

Tabela 2. Matriz de combinações entre PD e LGD utilizada no processo de elicitación

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	?	?	?	?
Moderado	?	?	?	?
Alto	?	?	?	?
Crítico	?	?	?	?

Fonte: Elaborado pelos autores (2026).

Para cada combinação apresentada, os participantes foram solicitados a atribuir uma classificação de risco pertencente às categorias Baixo, Moderado, Alto ou Crítico. Adicionalmente, foi solicitado que informassem seu grau de confiança na classificação atribuída, identificassem situações consideradas ambíguas e apresentassem justificativas relacionadas à influência relativa de PD e LGD sobre o risco final.

Além da classificação do cenário em condições normais, os participantes também foram convidados a avaliar o comportamento da matriz em um ambiente de estresse inspirado em eventos observados durante a crise financeira global de 2008. Essa etapa teve como objetivo investigar possíveis alterações na percepção de risco diante de cenários caracterizados por deterioração simultânea das condições econômicas e financeiras.

As respostas obtidas foram utilizadas para construir uma análise comparativa entre as diferentes fontes de conhecimento. Regiões de convergência foram interpretadas como indícios de maior consenso na classificação do risco, enquanto divergências foram consideradas evidências

da incerteza epistemológica inerente ao processo de modelagem.

A base de regras definitiva do sistema *Mamdani* será construída a partir da avaliação do especialista humano. As respostas produzidas pelos modelos de linguagem serão utilizadas como mecanismo complementar de validação qualitativa, permitindo identificar padrões de concordância e eventuais regiões de maior subjetividade na superfície de decisão do modelo.

3.5. Construção da Base de Regras Fuzzy

A base de regras constitui o núcleo lógico do sistema de inferência *fuzzy* adotado neste estudo. É por meio dela que o conhecimento obtido durante o processo de elicitação é convertido em uma estrutura formal capaz de relacionar as variáveis de entrada *Probability of Default* (PD) e *Loss Given Default* (LGD) ao Índice de Risco Composto (IRC).

A construção dessa base foi realizada a partir das classificações fornecidas pelas diferentes fontes de conhecimento descritas na seção anterior. Para cada combinação possível entre os níveis linguísticos de PD e LGD, foi atribuída uma categoria de risco pertencente ao conjunto de saída composto pelos níveis Baixo, Moderado, Alto e Crítico.

A utilização de quatro categorias linguísticas para cada variável de entrada resultou em uma matriz de dezesseis combinações possíveis. Cada célula da matriz corresponde a uma regra *fuzzy* do tipo:

$$SE\ PD\ é\ X\ E\ LGD\ é\ Y,\ ENTÃO\ IRC\ é\ Z$$

onde X e Y representam os níveis linguísticos das variáveis de entrada e Z corresponde à classificação de risco produzida pelo sistema.

Inicialmente, foram analisadas as classificações fornecidas pelos modelos de linguagem utilizados no processo de elicitação. O objetivo dessa etapa não foi determinar a regra definitiva do sistema, mas identificar padrões de convergência e divergência entre diferentes interpretações do problema. As Tabelas 3 e 4 apresentam as classificações propostas por cada modelo para as combinações entre PD e LGD.

Tabela 3. Base de regras proposta pelo ChatGPT

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Alto
Moderado	Baixo	Moderado	Alto	Alto
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Alto	Crítico	Crítico

Fonte: Obtido via interface programática junto ao ChatGPT (2026).

Tabela 4. Base de regras proposta pelo Claude

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Moderado
Moderado	Baixo	Moderado	Alto	Alto
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Crítico	Crítico	Crítico

Fonte: Obtido via interface programática junto ao Claude (2026).

Observa-se que a maior parte das classificações apresentou convergência entre os dois modelos. As divergências ficaram concentradas em cenários caracterizados por forte assimetria entre probabilidade de inadimplência e severidade da perda. Essas regiões correspondem justamente às situações em que a interpretação do risco tende a ser mais dependente do julgamento do avaliador.

As principais divergências identificadas ocorreram nas combinações:

- PD Baixo e LGD Crítico;
- PD Crítico e LGD Moderado.

Nesses casos, os modelos apresentaram interpretações distintas sobre o peso relativo exercido por cada variável na composição do risco final. Tal comportamento reforça a existência de incerteza epistemológica no processo de classificação e justifica a utilização de mecanismos formais de elicitación de conhecimento.

3.6. Elicitación e Validação com Especialista

Após a construção preliminar da base de regras a partir das classificações fornecidas pelos modelos de linguagem, foi conduzido um processo de elicitación junto a um especialista com experiência profissional em gestão de risco e análise de crédito. O objetivo dessa etapa foi incorporar conhecimento especializado ao modelo e validar as interpretações obtidas durante as fases anteriores da pesquisa.

O especialista consultado foi um profissional com ampla experiência na área financeira e de risco. Durante o processo de elicitación, foi solicitado que avaliasse diferentes aspectos relacionados à classificação de risco de crédito, dependência entre eventos de *default*, comportamento de parâmetros de risco e adequação da abordagem *fuzzy* proposta neste estudo.

Para garantir consistência metodológica, o especialista recebeu as mesmas definições conceituais e categorias linguísticas utilizadas nas etapas anteriores. As variáveis *Probability of Default* (PD) e *Loss Given Default* (LGD) foram apresentadas nos níveis Baixo, Moderado, Alto e Crítico, sendo solicitada a classificação do Índice de Risco Composto para todas as combinações possíveis entre essas categorias. A Tabela 5 apresenta a matriz resultante do processo de elicitación.

Tabela 5. Classificação do Índice de Risco Composto segundo o especialista

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Moderado
Moderado	Moderado	Moderado	Alto	Crítico
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Crítico	Crítico	Crítico

Fonte: Elaborado pelos autores a partir da elicitação realizada com o especialista (2026).

Além da classificação da matriz de risco, o especialista forneceu informações relevantes sobre sua interpretação dos fatores que influenciam a avaliação do risco de crédito. Em particular, destacou que a *Probability of Default* exerce papel predominante na classificação do risco, enquanto a *Loss Given Default* atua como um elemento complementar de ajuste. Essa percepção ficou evidente em situações nas quais uma LGD elevada não foi considerada suficiente para elevar significativamente a classificação de risco quando associada a níveis reduzidos de PD.

O especialista também indicou que a incerteza associada aos parâmetros de risco deve ser tratada de forma distinta da incerteza relacionada à ocorrência dos eventos de inadimplência, reconhecendo explicitamente a existência de diferentes tipos de incerteza no processo de modelagem. Adicionalmente, manifestou concordância com a representação de parâmetros como PD por meio de intervalos ou faixas de plausibilidade, em vez de valores pontuais únicos.

No que se refere à dependência entre eventos de *default*, o especialista reconheceu que cenários de crise tendem a produzir maior sincronização entre inadimplências, embora tenha atribuído à crise financeira de 2008 fatores adicionais além da correlação entre ativos, destacando questões relacionadas à transparência das carteiras, conflitos de interesse nas agências de classificação de risco e otimismo excessivo na estimação de parâmetros.

Por fim, o especialista avaliou positivamente a representação da PD por meio de faixas de valores e reconheceu o potencial da abordagem para representar explicitamente a incerteza presente nos parâmetros de risco. Entretanto, destacou que a aplicação prática de modelos dessa natureza pode enfrentar desafios relacionados à compreensão dos resultados, à contabilização das métricas produzidas e à incorporação dos conceitos em processos tradicionais de gestão financeira.

As informações obtidas nessa etapa serão utilizadas como referência principal para a construção da base final de regras do sistema de inferência *Mamdani*, sendo posteriormente comparadas às classificações produzidas pelos modelos de linguagem empregados neste estudo.

4. ANÁLISE DOS RESULTADOS

4.1. Comparação entre as Fontes de Conhecimento

Com o objetivo de avaliar a consistência das regras *fuzzy* propostas, foram comparadas as classificações atribuídas pelo ChatGPT (Versão GPT-5.5), Claude (Versão Sonnet 4.6) e pelo especialista José Monteiro Varanda Neto para as dezesseis combinações possíveis entre *Probability of Default* (PD) e *Loss Given Default* (LGD). A Tabela 14 e a Tabela 7 apresentam

o resumo e as divergências observadas.

Tabela 6. Resumo da concordância entre as fontes de conhecimento

Situação	Quantidade	Percentual
Concordância total (ChatGPT, Claude e Especialista)	11	68,75%
Concordância parcial (duas fontes concordam)	5	31,25%
Divergência total (três classificações diferentes)	0	0,00%
Total de combinações avaliadas	16	100,00%

Fonte: Elaborado pelos autores (2026).

Tabela 7. Combinações com divergência de classificação

Combinação	ChatGPT	Claude	Especialista
PD Baixo + LGD Crítico	Alto	Moderado	Moderado
PD Moderado + LGD Baixo	Baixo	Baixo	Moderado
PD Moderado + LGD Crítico	Alto	Alto	Crítico
PD Crítico + LGD Moderado	Alto	Crítico	Crítico

Fonte: Elaborado pelos autores (2026).

Observa-se elevado grau de concordância entre as classificações obtidas. Em onze das dezesseis combinações avaliadas houve concordância total entre as três fontes. As divergências concentraram-se em cenários de transição, nos quais PD e LGD indicam níveis distintos de risco.

De maneira geral, as três fontes apresentaram comportamento consistente, atribuindo classificações mais severas à medida que os níveis de PD e LGD aumentam. As diferenças observadas refletem interpretações distintas sobre a importância relativa de cada variável na composição do risco.

4.2. Análise de Convergência e Divergência

4.2.1. Regiões de Concordância entre os Três Avaliadores

A análise das classificações atribuídas pelo ChatGPT, Claude e pelo especialista revelou elevado grau de convergência na avaliação do risco de crédito. Das dezesseis combinações analisadas, onze apresentaram concordância integral entre as três fontes, indicando consistência na interpretação da relação entre *Probability of Default* (PD) e *Loss Given Default* (LGD).

As maiores concordâncias ocorreram nas regiões extremas da matriz. Cenários caracterizados simultaneamente por baixos níveis de PD e LGD foram classificados como de baixo risco por todas as fontes avaliadas. Da mesma forma, combinações envolvendo níveis elevados das duas variáveis foram sistematicamente classificadas como críticas.

Também foi observada convergência em situações intermediárias, como os cenários envolvendo PD moderada e LGD moderada, bem como PD alta e LGD baixa. Esses resultados

sugerem que, para a maior parte das combinações analisadas, existe consenso quanto à forma como as variáveis influenciam a classificação final do risco.

A elevada concordância observada fornece evidências de que a estrutura geral da base de regras *fuzzy* apresenta estabilidade qualitativa, independentemente da fonte de conhecimento utilizada para sua construção.

4.2.2. *Divergência na Combinação PD Baixo e LGD Crítico*

A primeira divergência observada ocorreu na combinação entre *Probability of Default* (PD) Baixo e *Loss Given Default* (LGD) Crítico. Nesse cenário, o ChatGPT classificou o risco como Alto, enquanto o Claude e o especialista atribuíram a classificação Moderado.

Essa diferença está relacionada à importância atribuída a cada variável na composição do risco. A classificação proposta pelo ChatGPT sugere maior sensibilidade à severidade da perda, interpretando que uma LGD crítica é suficiente para elevar significativamente o nível de risco, mesmo quando a probabilidade de inadimplência permanece reduzida.

Por outro lado, tanto o Claude quanto o especialista adotaram uma interpretação na qual a baixa probabilidade de ocorrência do evento limita o impacto da severidade da perda sobre a classificação final. Essa visão é consistente com as respostas fornecidas pelo especialista durante o processo de elicitación, nas quais foi indicado que uma PD reduzida tende a prevalecer na avaliação do risco, mesmo diante de perdas potencialmente elevadas em caso de *default*.

O resultado evidencia que, para cenários caracterizados por baixa frequência de inadimplência e elevada severidade de perda, diferentes avaliadores podem adotar pesos distintos para cada componente do risco. Essa característica reforça a presença de subjetividade na construção da base de regras e justifica a utilização de procedimentos formais de elicitación de conhecimento.

4.2.3. *Divergência na Combinação PD Moderado e LGD Baixo*

A combinação entre *Probability of Default* (PD) Moderado e *Loss Given Default* (LGD) Baixo representou a principal divergência observada entre o especialista e os modelos de linguagem. Enquanto ChatGPT e Claude classificaram esse cenário como Baixo, o especialista atribuiu a classificação Moderado.

Essa diferença sugere uma interpretação mais conservadora por parte do especialista. Para ele, o simples fato de a probabilidade de inadimplência ter ultrapassado a categoria de baixo risco já é suficiente para impedir uma classificação final na categoria Baixo, mesmo quando a severidade da perda é reduzida.

Esse entendimento é consistente com outras respostas fornecidas durante o processo de elicitación. Em diferentes situações avaliadas, o especialista demonstrou atribuir maior importância à *Probability of Default* na determinação do risco final, tratando a *Loss Given Default* como um fator complementar de ajuste. Dessa forma, uma LGD favorável pode mitigar parcialmente o risco, mas não é suficiente para compensar integralmente uma deterioração da PD.

Sob a perspectiva da modelagem *fuzzy*, essa divergência é particularmente relevante porque evidencia que a construção das regras não depende apenas dos valores atribuídos às variáveis, mas também da interpretação adotada sobre a relação entre frequência de inadimplência e severidade da perda. Nesse caso, o especialista adotou uma postura mais prudente do que a

observada nos modelos de linguagem, elevando a classificação final para refletir a presença de uma probabilidade de inadimplência já considerada significativa.

Por representar o único cenário em que o especialista divergiu simultaneamente do ChatGPT e do Claude, essa combinação destaca a importância da participação humana na validação da base de regras e reforça a necessidade de incorporar conhecimento especializado ao processo de modelagem.

4.2.4. *Divergência na Combinação PD Moderado e LGD Crítico*

Outra divergência relevante foi observada na combinação entre *Probability of Default* (PD) Moderado e *Loss Given Default* (LGD) Crítico. Nesse cenário, tanto o ChatGPT quanto o Claude atribuíram a classificação Alto, enquanto o especialista classificou o risco como Crítico.

A diferença observada sugere que o especialista interpreta a combinação de uma probabilidade de inadimplência já significativa com uma perda potencial extremamente elevada como uma situação capaz de produzir consequências suficientemente severas para justificar a classificação máxima de risco.

Diferentemente da divergência discutida na seção anterior, em que a baixa LGD foi considerada insuficiente para compensar uma PD moderada, neste caso a presença simultânea de uma PD não desprezível e de uma LGD crítica produz um efeito de reforço na percepção do risco. Essa interpretação indica que, para o especialista, determinadas combinações de frequência e severidade podem ultrapassar limites qualitativos que justificam uma classificação mais conservadora.

Sob a ótica da gestão de risco, essa decisão é coerente com situações em que perdas elevadas possuem potencial para gerar impactos financeiros relevantes mesmo quando a probabilidade de ocorrência não se encontra nos níveis mais altos da escala. Nesses casos, a severidade da perda passa a desempenhar papel mais importante na avaliação final.

A divergência observada demonstra que a classificação do risco não depende exclusivamente da posição individual de cada variável, mas também da forma como os avaliadores percebem a interação entre elas. Esse resultado reforça a utilidade da lógica *fuzzy* como ferramenta capaz de incorporar julgamentos especializados em situações nas quais não existem fronteiras objetivas entre categorias de risco.

4.2.5. *Divergência na Combinação PD Crítico e LGD Moderado*

A última divergência identificada ocorreu na combinação entre *Probability of Default* (PD) Crítico e *Loss Given Default* (LGD) Moderado. Nesse cenário, o ChatGPT atribuiu a classificação Alto, enquanto o Claude e o especialista classificaram o risco como Crítico.

Essa diferença decorre da forma como cada avaliador interpreta o peso da *Probability of Default* na composição do risco. Tanto o Claude quanto o especialista consideraram que uma PD classificada como crítica representa uma condition suficientemente severa para justificar a classificação máxima de risco, mesmo quando a perda esperada em caso de inadimplência permanece em níveis moderados.

A resposta do especialista é consistente com o padrão observado ao longo de todo o processo de elicitación, no qual a *Probability of Default* foi tratada como o principal determinante da classificação final. Nessa perspectiva, uma probabilidade extremamente elevada de

inadimplência representa uma ameaça significativa à qualidade da operação de crédito, reduzindo a capacidade de mitigação proporcionada por níveis intermediários de LGD.

Por outro lado, a classificação atribuída pelo ChatGPT sugere uma compensação parcial entre as variáveis, na qual uma LGD moderada reduz a severidade do risco final mesmo diante de uma PD crítica. Embora essa interpretação seja plausível, ela não foi compartilhada pelas demais fontes avaliadas.

A concordância entre Claude e especialista nesse cenário reforça a evidência observada em outras combinações analisadas, indicando maior proximidade entre essas duas fontes quanto à importância atribuída à *Probability of Default*. Esse resultado contribui para a compreensão dos critérios utilizados pelos avaliadores e fornece subsídios para a definição da base final de regras do sistema de inferência *fuzzy*.

4.3. Construção da Base Final de Regras

A análise comparativa realizada nas seções anteriores demonstrou elevado grau de concordância entre as classificações produzidas pelo ChatGPT, Claude e pelo especialista. Das dezesseis combinações avaliadas, onze apresentaram concordância integral entre as três fontes, enquanto las divergências ficaram restritas a cenários específicos de transição.

Considerando que o objetivo deste trabalho é incorporar conhecimento especializado à construção do sistema de inferência *fuzzy*, optou-se por adotar como referência principal a matriz fornecida pelo especialista. Essa decisão fundamenta-se na experiência profissional do avaliador e na consistência observada entre suas classificações e as justificativas apresentadas ao longo do processo de elicitação.


A matriz final utilizada na construção do sistema *Mamdani* é apresentada na Tabela 8.

Tabela 8. Base final de regras do sistema de inferência *fuzzy*

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Moderado
Moderado	Moderado	Moderado	Alto	Crítico
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Crítico	Crítico	Crítico

Fonte: Elaborado pelos autores a partir da elicitação realizada com José Monteiro Varanda Neto (2026).

A matriz final evidencia a predominância da *Probability of Default* na determinação do risco composto, aspecto recorrente nas respostas fornecidas pelo especialista. Observa-se que aumentos na PD tendem a produzir mudanças mais significativas na classificação final do que variações equivalentes na LGD, embora ambas as variáveis contribuam para a avaliação do risco. A Figura 2 ilustra o processo utilizado para consolidar as classificações obtidas pelas diferentes fontes de conhecimento e definir a base final de regras *fuzzy* adotada neste estudo.

Figura 2. Processo para consolidação das fontes de conhecimento

Fonte: Elaborado pelos autores (2026).

4.4. Interpretação do Especialista

As respostas fornecidas pelo especialista permitiram identificar padrões consistentes de avaliação do risco de crédito, complementando a análise realizada a partir da matriz de classificação. Além da atribuição das categorias de risco, o questionário possibilitou compreender os critérios utilizados na ponderação entre *Probability of Default* (PD) e *Loss Given Default* (LGD), bem como a percepção do especialista sobre incerteza, dependência e modelagem de risco.

4.4.1. Predominância da *Probability of Default*

Um dos resultados mais evidentes do processo de elicitación foi a predominância da *Probability of Default* na determinação da classificação final do risco. Em diferentes cenários avaliados, o especialista demonstrou atribuir maior importância à probabilidade de ocorrência da inadimplência do que à severidade da perda associada ao evento.

Essa característica pode ser observada na própria matriz de regras, especialmente em combinações nas quais níveis elevados de LGD não foram suficientes para produzir classificações extremas quando associados a valores reduzidos de PD. De forma semelhante, cenários caracterizados por elevada probabilidade de inadimplência receberam classificações severas mesmo quando a perda esperada permaneceu em níveis moderados.

Os resultados sugerem que, na percepção do especialista, a frequência potencial dos eventos de inadimplência exerce influência mais significativa sobre o risco global da operação do que a magnitude da perda observada após o *default*. Essa interpretação mostrou-se consistente ao longo de todo o processo de elicitación e constituiu o principal fator responsável pelas diferenças observadas em relação às classificações produzidas pelos modelos de linguagem.

4.4.2. *Papel Complementar da Loss Given Default*

Embora a *Probability of Default* tenha sido identificada como a principal variável na composição do risco, a *Loss Given Default* também desempenhou papel relevante nas classificações atribuídas pelo especialista.

As respostas indicam que a LGD atua como um mecanismo de ajuste da severidade do risco, tornando-se particularmente importante quando associada a níveis moderados ou elevados de PD. Nesses casos, aumentos na perda potencial tendem a elevar a classificação final do risco, podendo inclusive deslocar determinadas combinações para categorias mais severas.

Por outro lado, quando a probabilidade de inadimplência permanece reduzida, a influência da LGD torna-se mais limitada. Essa característica explica parte das divergências observadas entre as diferentes fontes de conhecimento e reforça a interpretação de que o especialista utiliza uma estrutura hierárquica de avaliação, na qual a probabilidade de ocorrência do evento é analisada antes da severidade potencial da perda.

Dessa forma, a LGD não é ignorada no processo decisório, mas atua como uma variável complementar responsável por refinar a classificação produzida a partir da avaliação da PD.

4.4.3. *Dependência entre PD e LGD*

Outro aspecto relevante identificado durante o processo de elicitación foi a percepção de que *Probability of Default* e *Loss Given Default* não devem ser interpretadas como variáveis completamente independentes. Embora o especialista tenha reconhecido a utilidade de analisá-las separadamente para fins de modelagem, suas respostas indicam que existe uma relação de dependência entre ambas em diversos contextos de risco.

Essa percepção torna-se particularmente evidente em cenários de crise, nos quais o aumento das taxas de inadimplência tende a ocorrer simultaneamente à redução das taxas de recuperação dos ativos. Nesses ambientes, não apenas mais operações entram em *default*, mas as perdas associadas a esses eventos também podem se tornar mais severas em razão da deterioração das condições econômicas e da redução do valor das garantias.

O especialista também reconheceu que eventos de inadimplência tendem a apresentar maior sincronização durante períodos de estresse financeiro, reforçando a importância da dependência entre fatores de risco na avaliação de carteiras de crédito. Essa interpretação é consistente com a literatura de risco de crédito, que destaca a relevância da modelagem da dependência entre eventos de *default* para a adequada mensuração de perdas extremas.

Sob a perspectiva deste estudo, esse resultado possui especial relevância porque reforça a motivação para utilização conjunta de técnicas probabilísticas e sistemas *fuzzy*. Enquanto a lógica *fuzzy* permite representar a incerteza associada à definição dos parâmetros de risco, ferramentas como as cópulas possibilitam modelar a dependência entre eventos de inadimplência. Dessa forma, ambas as abordagens podem ser interpretadas como complementares na construção de modelos mais aderentes à realidade observada nos mercados financeiros.

As respostas obtidas sugerem que a representação adequada do risco de crédito não depende apenas da estimação individual de PD e LGD, mas também da compreensão das relações existentes entre essas variáveis e do comportamento conjunto dos eventos de *default* em diferentes condições econômicas.

4.5. Implementação Computacional

A base final de regras definida a partir do processo de elicitação foi utilizada como entrada para a implementação computacional do sistema de inferência *fuzzy* em linguagem R. O modelo foi estruturado segundo a arquitetura clássica de *Mamdani*, contemplando as etapas de fuzzificação das variáveis de entrada, avaliação das regras, agregação dos resultados e defuzzificação da saída.

A implementação foi desenvolvida de forma modular, permitindo futuras alterações nas funções de pertinência e na base de regras. Essa característica possibilita a expansão do modelo para inclusão de novas variáveis e sua aplicação em diferentes contextos de avaliação de risco de crédito. Os principais trechos do código desenvolvido são apresentados no Apêndice C.

4.6. Limitações dos Resultados Obtidos

Os resultados apresentados neste trabalho devem ser interpretados considerando algumas limitações inerentes ao processo de pesquisa. A principal delas refere-se ao número de especialistas consultados. Embora o processo de elicitação tenha sido conduzido com um profissional experiente na área de risco de crédito, a incorporação de múltiplos especialistas poderia ampliar a representatividade das classificações obtidas e reduzir potenciais vieses individuais.

Outra limitação está relacionada à natureza qualitativa dos resultados. O foco deste estudo concentrou-se na construção e validação da base de regras *fuzzy*, não contemplando, nesta etapa, a implementação completa do sistema de inferência e a realização de experimentos quantitativos para avaliação de desempenho.

Adicionalmente, as classificações produzidas pelos modelos de linguagem foram utilizadas exclusivamente como fontes auxiliares de comparação e não devem ser interpretadas como substitutas do conhecimento especializado. Seu papel consistiu em fornecer referências adicionais para análise das convergências e divergências observadas durante o processo de elicitação.

Por fim, a estrutura proposta considera apenas as variáveis *Probability of Default* e *Loss Given Default*. Embora essas métricas representem componentes fundamentais do risco de crédito, outros fatores, como exposição ao *default*, concentração de carteira e dependência entre eventos de inadimplência, podem influenciar significativamente a avaliação do risco e constituem oportunidades para o desenvolvimento de trabalhos futuros.

5. DISCUSSÃO

5.1. Incerteza Epistemológica e Construção das Regras

As divergências observadas entre os modelos de linguagem e o especialista indicam que a classificação do risco de crédito não depende exclusivamente dos valores numéricos brutos de *Probability of Default* (PD) e *Loss Given Default* (LGD), mas também da interpretação metodológica adotada pelos avaliadores. Esse comportamento caracteriza perfeitamente a presença de incerteza epistemológica, a qual Cont [8] define como aquela associada às limitações do conhecimento disponível e à subjetividade inerente à definição de parâmetros e regras de classificação.

Os resultados obtidos demonstram que diferentes fontes podem produzir avaliações distintas para uma mesma combinação de variáveis, mesmo quando munidas das mesmas in-

formações de entrada. Nesse contexto, em linha com os preceitos pioneiros de Zadeh [1], a utilização de técnicas de elicitación combinadas a sistemas *fuzzy* permite representar de forma mais transparente as incertezas presentes no processo de modelagem, oferecendo um tratamento matemático rigoroso para conceitos que seriam erroneamente classificados como puramente determinísticos.

5.2. Contribuições da Abordagem Fuzzy para o Risco de Crédito

Os resultados obtidos neste estudo indicam que a lógica *fuzzy* pode atuar como uma robusta ferramenta complementar aos modelos tradicionais de risco de crédito, cuja modelagem probabilística rígida por vezes falha em capturar nuances qualitativas [14]. Ao permitir a representação de categorias linguísticas e regiões de transição entre diferentes níveis de risco, a abordagem matemática baseada no ambiente proposto por Bellman e Zadeh [13] oferece uma alternativa para incorporar julgamentos especializados de forma estruturada e transparente.

A comparação entre as classificações fornecidas pelas ferramentas de inteligência artificial e pelo especialista demonstrou que diferentes interpretações surgem mesmo quando as variáveis analisadas são idênticas. Sob a ótica de Klir e Yuan [12], a utilização de sistemas baseados em regras permite documentar e representar explicitamente essa subjetividade, mitigando a falsa percepção de precisão matemática estrita frequentemente associada à divulgação de valores pontuais na gestão de risco corporativo.

Além disso, o emprego do método clássico de Mamdani e Assilian [18] possibilita a integração nativa entre o conhecimento empírico especializado e as técnicas quantitativas exigidas pelos comitês internacionais de supervisão [9]. Essa característica é particularmente relevante no cenário atual de governança bancária, no qual a interpretabilidade e a auditabilidade das regras utilizadas para classificação do risco tornam-se tão fundamentais quanto os resultados preditivos numéricos finais produzidos pelo modelo [10].

Dessa forma, a principal contribuição da abordagem não reside na substituição dos métodos probabilísticos ou estatísticos clássicos de previsão de insolvência [16], mas sim na sua complementação prática através da representação formal da vagueza conceitual dos parâmetros.

5.3. Limitações e Trabalhos Futuros

Apesar das contribuições estruturais apresentadas, este estudo possui limitações que demandam cautela na extrapolação imediata dos resultados. A principal delas refere-se ao escopo do processo de elicitación conduzido com um único especialista humano. Embora a experiência do profissional consultado confira validade ao modelo, a literatura indica que a incorporação de múltiplos tomadores de decisão tende a diluir vieses individuais e enriquecer a base de regras [11].

Adicionalmente, o trabalho concentrou-se na definição e validação qualitativa das matrizes de inferência controlador-resposta, operando como um arcabouço conceitual inicial para o desenho do Índice de Risco Composto (IRC). Testes de estresse quantitativos sistêmicos baseados em dados históricos de mercado e análises de superfícies de decisão tridimensionais contínuas não integraram o escopo desta seção.

Como oportunidade para investigações futuras, recomenda-se a expansão do experimento de elicitación por meio de painéis interativos ou rodadas de consenso (como o método

Delphi), aplicando a modelagem computacional para confrontar estatisticamente a performance do sistema *fuzzy* contra modelos tradicionais de pontuação de crédito.

Por fim, aponta-se como caminho promissor a integração desta arquitetura com ferramentas multivariadas de dependência de cauda, tais como as construções de cópulas em vinhas [6], [7]. Essa fusão permitirá avaliar de maneira simultânea a incerteza dos parâmetros individuais (PD e LGD) via lógica *fuzzy* e a dinâmica de co-movimento e contágio financeiro de ativos em cenários de quebras estruturais e estresse macroeconômico [3], [5].

6. CONCLUSÃO

6.1. Considerações Finais

A modelagem de risco de crédito envolve diferentes fontes de incerteza que nem sempre são adequadamente representadas por abordagens estatísticas tradicionais baseadas exclusivamente em parâmetros pontuais [14]. Nesse contexto, este trabalho investigou a utilização da lógica *fuzzy* como ferramenta complementar à avaliação do risco, buscando representar explicitamente a imprecisão presente na definição e interpretação de variáveis amplamente utilizadas no mercado financeiro global, como a *Probability of Default* (PD) e a *Loss Given Default* (LGD).

Para atingir esse objetivo, foi desenvolvido um procedimento de elicitação de conhecimento envolvendo diferentes fontes independentes, incluindo modelos de linguagem de grande porte e um especialista com ampla experiência na área de risco de crédito. A comparação das classificações obtidas permitiu identificar regiões de convergência e divergência na avaliação do risco, evidenciando que diferentes agentes e tecnologias podem interpretar de maneira distinta uma mesma combinação de parâmetros.

Os resultados mostraram um elevado grau de concordância entre as fontes consultadas, ao mesmo tempo em que revelaram a existência de incerteza epistemológica associada ao processo de classificação, tal como mapeado na literatura clássica de sistemas vagos [12]. As divergências observadas concentraram-se em cenários de transição, nos quais a importância relativa atribuída à *Probability of Default* e à *Loss Given Default* variou entre os avaliadores.

A partir da análise realizada, foi possível construir uma base final de regras *fuzzy* fundamentada no conhecimento especializado obtido durante o processo de elicitação. Essa estrutura constitui o principal resultado do estudo e fornece os elementos necessários para a futura implementação de um sistema de inferência *fuzzy* do tipo *Mamdani* aplicado à avaliação do risco de crédito [18].

Dessa forma, conclui-se que a lógica *fuzzy* apresenta um elevado potencial para complementar abordagens probabilísticas tradicionais [1], contribuindo para uma representação mais transparente da incerteza presente nos parâmetros de risco e nos processos de tomada de decisão. Embora a abordagem proposta não substitua os métodos convencionais de modelagem exigidos pelo regulador [10], sua capacidade de incorporar conhecimento especializado e representar conceitos graduais constitui uma alternativa promissora para aplicações futuras em gestão de risco de crédito.

6.2. Contribuições do Estudo

Este trabalho contribui para a discussão sobre a representação da incerteza em modelos de risco de crédito ao propor uma abordagem baseada em lógica *fuzzy* para a integração en-

tre *Probability of Default* (PD) e *Loss Given Default* (LGD). Diferentemente de modelos que utilizam exclusivamente valores pontuais, a metodologia desenvolvida busca incorporar a subjetividade presente na interpretação dos parâmetros de risco e no processo de tomada de decisão, aproximando-se dos conceitos estruturais de decisão em ambientes complexos defendidos por Bellman e Zadeh [13].

Uma contribuição relevante do estudo foi a utilização de múltiplas fontes de conhecimento para a construção da base de regras *fuzzy*. A comparação inédita entre classificações produzidas por modelos de linguagem e por um especialista da área permitiu identificar regiões de consenso e divergência, fornecendo evidências empíricas sobre a existência de incerteza epistemológica na avaliação do risco de crédito [8].

Além disso, o trabalho estabeleceu uma estrutura metodológica clara para a elicitación, comparação e consolidação de regras *fuzzy* aplicadas ao contexto financeiro. A base final de regras obtida constitui um resultado prático da pesquisa e representa o ponto de partida ideal para futuras implementações computacionais do sistema de inferência *Mamdani*.

Por fim, o estudo reforça a importância da integração entre conhecimento especializado e técnicas quantitativas, demonstrando que abordagens baseadas em conjuntos *fuzzy* podem contribuir para aumentar a transparência e a interpretabilidade dos modelos utilizados na gestão de risco corporativo e bancário [9].

6.3. Trabalhos Futuros

Os resultados obtidos neste estudo representam uma etapa inicial na construção de um modelo *fuzzy* aplicado à avaliação do risco de crédito. Como continuidade natural desta pesquisa, recomenda-se a implementação computacional completa do sistema de inferência *Mamdani* em ambiente de programação (como a linguagem R), permitindo a realização de simulações e análises quantitativas a partir da base de regras desenvolvida.

Outra oportunidade de pesquisa consiste na ampliação do processo de elicitación, incorporando especialistas de diferentes áreas de atuação e instituições financeiras. Essa expansão permitiria avaliar o grau de consenso entre profissionais do mercado através de abordagens multiagente estruturadas [11], investigando possíveis diferenças de percepção relacionadas à experiência, ao setor de atuação ou ao perfil institucional.

Também se mostra altamente relevante explorar a inclusão de variáveis adicionais no modelo, como a exposição ao *default* (EAD), a concentração de carteira e, fundamentalmente, medidas não lineares de dependência entre eventos de inadimplência, tais como as funções de cópula [3], [19]. A incorporação de estruturas de cópulas multivariadas e construções em vinhas [6], [7] pode contribuir para uma representação mais abrangente do risco de cauda e contágio sistêmico [17].

Por fim, recomenda-se a aplicação da metodologia em carteiras reais de crédito bancário e a comparação de seus resultados com aqueles obtidos por modelos tradicionais de *credit scoring* baseados em redes neurais ou regressões logísticas [16]. Essa etapa final de validação empírica permitirá avaliar o real potencial da abordagem *fuzzy* como ferramenta complementar para o apoio à decisão e para a gestão de risco em ambientes financeiros altamente complexos e voláteis.

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Ferramentas de inteligência artificial foram utilizadas neste trabalho exclusivamente como instrumentos de apoio à pesquisa. Modelos de linguagem de grande porte foram empregados como fontes auxiliares no processo de elicitación de conhecimento utilizado para a construção preliminar da base de regras do sistema de inferência *fuzzy*, conforme descrito na metodologia.

Além disso, ferramentas de inteligência artificial foram utilizadas para apoio na organização textual, revisão de redação e aprimoramento da estrutura do manuscrito. Nenhuma informação produzida pelas ferramentas foi incorporada ao trabalho sem análise crítica dos autores.

Todas as decisões relacionadas à definição do problema de pesquisa, fundamentação teórica, metodologia adotada, interpretação dos resultados, discussão dos achados e conclusões do estudo foram realizadas pelos autores. Da mesma forma, a seleção das referências bibliográficas, a análise técnica do conteúdo e a validação das informações apresentadas permanecem sob responsabilidade exclusiva dos pesquisadores.

As ferramentas de inteligência artificial foram empregadas como recursos de suporte à escrita e à elicitación de conhecimento, não substituindo o julgamento técnico, científico ou acadêmico dos autores em nenhuma etapa da pesquisa.

CONTRIBUIÇÃO DOS AUTORES (CRÉDITOS)

Para fins de transparência e atribuição de responsabilidades, as contribuições individuais dos autores foram distribuídas conforme os critérios abaixo:

- **Matheus Nascimento:** Conceitualização, Metodologia, Software, Investigação, Escrita – Versão Inicial (*Original Draft*), Escrita – Revisão e Edição.
- **Breno Molon:** Conceitualização, Investigação, Metodologia, Escrita – Versão Inicial (*Original Draft*), Escrita – Revisão e Edição.
- **Marina Rosa:** Conceitualização, Investigação, Escrita – Versão Inicial (*Original Draft*), Escrita – Revisão e Edição.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] L. A. Zadeh, “Fuzzy sets,” *Information and Control*, v. 8, n. 3, pp. 338–353, 1965.
- [2] A. Sklar, “Fonctions de répartition à n dimensions et leurs marges,” *Publications de l’Institut de Statistique de l’Université de Paris*, v. 8, pp. 229–231, 1959.
- [3] D. X. Li, “On default correlation: a copula function approach,” *Journal of Fixed Income*, v. 9, n. 4, pp. 43–54, 2000.
- [4] P. Embrechts, A. J. McNeil e D. Straumann, “Correlation and dependence in risk management,” em *Risk management: value at risk and beyond*, M. A. H. Dempster, ed., Cambridge: Cambridge University Press, 2002, pp. 176–223.
- [5] S. R. Das, D. Duffie, N. Kapadia e L. Saita, “Common failings: how corporate defaults are correlated,” *The Journal of Finance*, v. 62, n. 1, pp. 93–117, 2007.
- [6] K. Aas, C. Czado, A. Frigessi e H. Bakken, “Pair-copula constructions of multiple dependence,” *Insurance: Mathematics and Economics*, v. 44, n. 2, pp. 182–198, 2009.
- [7] E. C. Brechmann e C. Czado, “Risk management with high-dimensional vine copulas,” *Statistics & Risk Modeling*, v. 30, n. 4, pp. 307–342, 2013.
- [8] R. Cont, “Model uncertainty and its impact on the pricing of derivative instruments,” *Mathematical Finance*, v. 16, n. 3, pp. 519–547, 2006.
- [9] Basel Committee on Banking Supervision, “Studies on the validation of internal rating systems,” Bank for International Settlements, Basel, 2005.
- [10] Basel Committee on Banking Supervision, “Regulatory consistency assessment programme (RCAP): analysis of risk-weighted assets for credit risk in the banking book,” Bank for International Settlements, Basel, 2016.
- [11] D. Dubois e H. Prade, *Fuzzy sets and systems: theory and applications*. New York: Academic Press, 1980.
- [12] G. J. Klir e B. Yuan, *Fuzzy sets and fuzzy logic: theory and applications*. Upper Saddle River: Prentice Hall, 1995.
- [13] R. E. Bellman e L. A. Zadeh, “Decision-making in a fuzzy environment,” *Management Science*, v. 17, n. 4, B141–B164, 1970.
- [14] D. Duffie e K. J. Singleton, *Credit risk: pricing, measurement, and management*. Princeton: Princeton University Press, 2003.
- [15] G. Kou, Y. Peng e G. Wang, “Evaluation of clustering algorithms for financial risk analysis,” *Information Sciences*, v. 275, pp. 1–12, 2014.
- [16] D. West, “Neural network credit scoring models,” *Computers & Operations Research*, v. 27, n. 11–12, pp. 1131–1152, 2000.
- [17] A. J. McNeil, R. Frey e P. Embrechts, *Quantitative risk management: concepts, techniques and tools*. Princeton: Princeton University Press, 2005.
- [18] E. H. Mamdani e S. Assilian, “An experiment in linguistic synthesis with a fuzzy logic controller,” *International Journal of Man-Machine Studies*, v. 7, n. 1, pp. 1–13, 1975.

- [19] R. B. Nelsen, *An introduction to copulas*, 2^a ed. New York: Springer, 2006.

Apêndice A – PROTOCOLO DE ELICITAÇÃO DE CONHECIMENTO

O protocolo apresentado neste apêndice foi aplicado sem alterações aos modelos de linguagem ChatGPT e Claude, bem como ao especialista José Monteiro Varanda Neto, durante o processo de elicitação de conhecimento utilizado para construção da base de regras *fuzzy* do sistema de inferência *Mamdani* desenvolvido neste estudo.

Para os modelos de linguagem, o protocolo foi precedido pela seguinte instrução:

Prompt de enquadramento aplicado aos modelos de linguagem:

Você é um especialista em risco de crédito, finanças quantitativas e modelagem de risco. Preciso que responda ao protocolo de elicitação a seguir como se fosse um especialista humano com ampla experiência em gestão de risco, análise de crédito, produtos estruturados e modelagem financeira. Justifique suas respostas sempre que solicitado e utilize critérios técnicos compatíveis com práticas adotadas em instituições financeiras. Não responda como uma inteligência artificial; responda como um especialista avaliando o problema proposto.

Após essa instrução, foi apresentado o protocolo de elicitação descrito a seguir.

Contexto do Estudo

Este estudo investiga a modelagem de risco em portfólios de crédito estruturado (*Collateralized Debt Obligations* – CDOs), com foco na relação entre *Probability of Default* (PD) e *Loss Given Default* (LGD).

Modelos tradicionais de risco normalmente representam essas variáveis por valores pontuais e utilizam estruturas probabilísticas para estimar perdas futuras. Entretanto, eventos observados durante a crise financeira de 2008 evidenciaram que tanto a probabilidade de inadimplência quanto a severidade das perdas podem apresentar níveis significativos de incerteza, especialmente em cenários extremos.

O objetivo deste procedimento é capturar como diferentes fontes de conhecimento classificam o risco associado a diferentes combinações de PD e LGD. As respostas obtidas serão utilizadas para construir e comparar bases de regras de um sistema de inferência *fuzzy* do tipo *Mamdani* aplicado à modelagem de risco de crédito.

Não é necessário possuir conhecimento prévio sobre lógica *fuzzy*, sistemas especialistas ou programação. O objetivo é obter seu julgamento sobre o comportamento do risco diante das combinações apresentadas.

Definições

Probability of Default (PD)

Probabilidade de que um ativo, empréstimo ou contraparte entre em inadimplência. Categorias: Baixo; Moderado; Alto; Crítico.

Loss Given Default (LGD)

Percentual de perda esperado caso ocorra inadimplência. Categorias: Baixo; Moderado; Alto; Crítico.

Índice de Risco Composto (IRC)

Classificação geral de risco resultante da combinação entre PD e LGD. Categorias: Baixo; Moderado; Alto; Crítico.

Questões do Protocolo

Questão 1 – Classificação do Risco

Preencha a tabela abaixo indicando qual deveria ser a classificação do Índice de Risco Composto (IRC) para cada combinação de PD e LGD.

Tabela 9. Matriz para classificação do Índice de Risco Composto (IRC)

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	?	?	?	?
Moderado	?	?	?	?
Alto	?	?	?	?
Crítico	?	?	?	?

Questão 2 – Grau de Confiança

Para cada classificação atribuída na tabela anterior, indique seu grau de confiança entre 0% e 100%.

Tabela 10. Exemplo de preenchimento para o Grau de Confiança

Combinação	Classificação	Confiança
PD Alto + LGD Alto	Crítico	95%
PD Moderado + LGD Alto	Alto	70%

Questão 3 – Ambiguidade

Quais combinações de PD e LGD você considera mais difíceis de classificar? Explique brevemente o motivo.

Questão 4 – Sensibilidade

Na sua opinião, qual variável exerce maior influência sobre o risco final?

- (a) *Probability of Default* (PD)
- (b) *Loss Given Default* (LGD)
- (c) Ambas possuem influência semelhante

Justifique sua resposta.

Questão 5 – Cenário de Estresse

Considere um cenário semelhante à crise financeira global de 2008.

- Quais combinações da matriz se tornam mais críticas?
- Alguma classificação deveria ser alterada?
- A severidade do risco deveria aumentar mesmo mantendo a mesma categoria linguística?

Explique brevemente.

Questão 6 – Comentários Finais

Existe alguma observação adicional sobre a relação entre PD, LGD e risco de crédito que considere relevante para a modelagem do problema?

Apêndice B – RESULTADOS DA ELICITAÇÃO

Este apêndice apresenta os resultados obtidos a partir da aplicação do protocolo de elicitação descrito no Apêndice A aos modelos de linguagem ChatGPT e Claude, bem como ao especialista José Monteiro Varanda Neto.

B.1. Respostas Obtidas com o ChatGPT

B.1.1. Matriz de Classificação

Tabela 11. Matriz de classificação do Índice de Risco Composto (IRC) proposta pelo ChatGPT

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Alto
Moderado	Baixo	Moderado	Alto	Alto
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Alto	Crítico	Crítico

B.1.2. Combinações Consideradas Ambíguas

- PD Baixo + LGD Crítico
- PD Moderado + LGD Crítico
- PD Crítico + LGD Baixo
- PD Alto + LGD Baixo

B.1.3. Variável de Maior Influência

Probability of Default (PD): Segundo o modelo, a inadimplência representa o gatilho para materialização da perda, fazendo com que aumentos na PD tenham impacto mais significativo sobre o risco agregado.

B.1.4. Cenário de Estresse

As combinações consideradas mais críticas foram: PD Alto + LGD Alto, PD Alto + LGD Crítico, PD Crítico + LGD Alto e PD Crítico + LGD Crítico. Também foi sugerida a reclassificação de cenários intermediários, como PD Moderado + LGD Crítico e PD Crítico + LGD Moderado, para a categoria Crítico.

B.2. Respostas Obtidas com o Claude

B.2.1. Matriz de Classificação

Tabela 12. Matriz de classificação do Índice de Risco Composto (IRC) proposta pelo Claude

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Moderado
Moderado	Baixo	Moderado	Alto	Alto
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Crítico	Crítico	Crítico

B.2.2. Combinações Consideradas Ambíguas

- PD Baixo + LGD Crítico
- PD Crítico + LGD Baixo
- PD Alto + LGD Alto

B.2.3. Variável de Maior Influência

Loss Given Default (LGD): Segundo o modelo, a severidade da perda representa o principal factor diferenciador entre situações administráveis e perdas potencialmente catastróficas.

B.2.4. Cenário de Estresse

As combinações mais afetadas foram: PD Moderado + LGD Alto, PD Baixo + LGD Crítico e PD Alto + LGD Moderado. O modelo destacou que, em ambientes de crise, PD e LGD tendem a se deteriorar simultaneamente, aumentando o risco composto.

B.3. Respostas Obtidas com o Especialista

B.3.1. Matriz de Classificação

Tabela 13. Matriz de classificação do Índice de Risco Composto (IRC) proposta pelo especialista

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Moderado
Moderado	Moderado	Moderado	Alto	Crítico
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Crítico	Crítico	Crítico

B.3.2. Combinações Consideradas Mais Sensíveis

O especialista indicou que os cenários envolvendo combinações intermediárias entre PD e LGD representam as regiões de maior subjetividade na classificação do risco, especialmente

quando uma variável indica baixa severidade e a outra aponta elevado risco potencial.

B.3.3. Variável de Maior Influência

Probability of Default (PD): O especialista destacou que a probabilidade de inadimplência exerce papel predominante na classificação do risco, enquanto a LGD atua como mecanismo complementar de ajuste da severidade.

B.3.4. Cenário de Estresse

O especialista observou que cenários de crise tendem a aumentar simultaneamente a probabilidade de inadimplência e a severidade das perdas, reforçando a dependência entre PD e LGD e elevando a criticidade das combinações localizadas nas regiões superiores da matriz.

B.4. Comparação das Classificações

Tabela 14. Resumo da concordância entre as fontes de conhecimento

Situação	Quantidade
Concordância total	11
Concordância parcial	5
Divergência total	0
Total de combinações	16

Fonte: Elaborado pelos autores (2026).

B.5. Base Final de Regras Adotada no Estudo

Considerando a experiência do especialista e a consistência observada durante o processo de elicitación, a matriz apresentada na Tabela 15 foi adotada como base final de regras do sistema de inferência *fuzzy*.

Tabela 15. Matriz final de regras adotada para o sistema de inferência *fuzzy*

PD \ LGD	Baixo	Moderado	Alto	Crítico
Baixo	Baixo	Baixo	Moderado	Moderado
Moderado	Moderado	Moderado	Alto	Crítico
Alto	Moderado	Alto	Crítico	Crítico
Crítico	Alto	Crítico	Crítico	Crítico

Fonte: Elaborado pelos autores (2026).

Apêndice C – ESTRUTURA E IMPLEMENTAÇÃO COMPUTACIONAL DO SISTEMA DE INFERÊNCIA MAMDANI

Este apêndice apresenta os principais trechos do código desenvolvido para a implementação computacional do sistema de inferência *fuzzy* descrito na Seção 4.5. A arquitetura clássica de *Mamdani* — fuzzificação, avaliação das regras, agregação e defuzzificação — foi implementada de forma modular, tomando como entrada a base final de regras obtida no processo de elicitacão (Tabela 8). O sistema foi integrado a uma aplicação interativa que permite explorar a superfície de decisão, a análise de convergência entre as fontes de conhecimento e as camadas complementares de dependência (cópulas) e propagação de incerteza (simulação de Monte Carlo de segunda ordem).

Nota sobre a linguagem de implementação: Embora a literatura de referência da disciplina utilize pacotes em R (*sets*, *FuzzyNumbers*, *FRBS*, *lfi*), a implementação foi desenvolvida em *Python*, por meio da biblioteca *scikit-fuzzy* (*skfuzzy*), que oferece correspondência direta às funcionalidades necessárias. A Seção C.9 apresenta a tabela de correspondência entre os pacotes.

C.1. Variáveis de Entrada

As variáveis de entrada *Probability of Default* (PD) e *Loss Given Default* (LGD) compartilham o mesmo universo de discurso normalizado no intervalo $[0, 1]$ e as mesmas quatro categorias linguísticas — Baixo, Moderado, Alto e Crítico — conforme definido na Tabela 1. O universo é discretizado em 201 pontos para suportar as operações de fuzzificação e defuzzificação.

Listing 1. Definição das variáveis de entrada e do universo de discurso.

```

1 import numpy as np
2 import skfuzzy as fuzz
3
4 # Categorias linguísticas comuns a PD, LGD e IRC
5 CATEGORIAS = ["Baixo", "Moderado", "Alto", "Crítico"]
6
7 # Universo de discurso normalizado [0, 1], discretizado em 201 pontos.
8 # PD, LGD e IRC compartilham a mesma escala linguística (Seção
   3.2.4).
9 UNIVERSO = np.linspace(0.0, 1.0, 201)
```

Fonte: Elaborado pelos autores (2026).

C.2. Variável de Saída

A variável de saída — o *Índice de Risco Composto* (IRC) — utiliza a mesma escala e as mesmas categorias das variáveis de entrada, facilitando a interpretação dos resultados. Após a defuzzificação, o valor numérico do IRC é reconvertido em categoria linguística pela função abaixo, que identifica a categoria de maior grau de pertinência.

Listing 2. Mapeamento do IRC numérico para categoria linguística.

```

1 def irc_para_categoria(irc):
```

```

2      """Retorna a categoria linguística dominante para um valor de IRC.
      """
3      mu = fuzzificar(irc)
4      return max(mu, key=mu.get)

```

Fonte: Elaborado pelos autores (2026).

C.3. Funções de Pertinência

Conforme a Seção 3.3, foram adotadas funções de pertinência triangulares, cada categoria definida por três parâmetros (limite inferior, modal e superior). As quatro categorias particionam o intervalo $[0, 1]$ com picos em 0, $1/3$, $2/3$ e 1, permitindo que uma mesma observação pertença simultaneamente a categorias adjacentes.

Listing 3. Funções de segurança e pertinência triangulares e fuzzificação.

```

1  # Parâmetros (a, m, b) das funções triangulares de cada categoria.
2  # Picos uniformemente distribuídos em 0, 1/3, 2/3 e 1.
3  MF_PARAMS = {
4      "Baixo": [0.00, 0.00, 0.34],
5      "Moderado": [0.00, 0.34, 0.67],
6      "Alto": [0.34, 0.67, 1.00],
7      "Crítico": [0.67, 1.00, 1.00],
8  }
9
10 def funcoes_pertinencia(universo=UNIVERSO):
11     """Retorna {categoria: vetor de segurança e pertinência} sobre o
12     universo."""
13     return {cat: fuzz.trimf(universo, MF_PARAMS[cat]) for cat in
14             CATEGORIAS}
15
16 def fuzzificar(valor, universo=UNIVERSO):
17     """Etapa 1 (fuzzificação): converte um valor crisp em graus de
18     pertinência a cada categoria linguística."""
19     mfs = funcoes_pertinencia(universo)
20     return {cat: float(fuzz.interp_membership(universo, mfs[cat], valor))
21             for cat in CATEGORIAS}

```

Fonte: Elaborado pelos autores (2026).

C.4. Processo de Inferência

A base final de regras (Tabela 8) é representada por uma matriz 4×4 indexada por [categoria de PD] [categoria de LGD]. O processo de inferência avalia todas as regras ativas, combinando os antecedentes pelo operador **E (AND) = mínimo** e agregando os consequentes pelo operador **máximo**, com truncamento das funções de saída (implicação de Mamdani).

Listing 4. Base final de regras e processo de inferência Mamdani.

```

1  # Base final de regras (Tabela 8), obtida da elicitação com o
    especialista.
2  # Ordem das linhas (PD) e colunas (LGD): Baixo, Moderado, Alto,
    Crítico.
3  BASES_REGRAS = {
4      "Especialista": [
5          ["Baixo", "Baixo", "Moderado", "Moderado"],
6          ["Moderado", "Moderado", "Alto", "Crítico"],
7          ["Moderado", "Alto", "Crítico", "Crítico"],
8          ["Alto", "Crítico", "Crítico", "Crítico"],
9      ],
10 }
11 BASE_FINAL = "Especialista"
12
13 def inferir_mamdani(pd_val, lgd_val, base="Especialista", universo=
    UNIVERSO):
14     """Sistema de inferência Mamdani completo:
15         (1) fuzzifica o (2) avalia o das regras (3) agrega o
16         (4) defuzzifica o por centroide. Retorna o IRC em [0, 1]."""
17     mfs = funcoes_pertinencia(universo)
18     mu_pd = fuzzificar(pd_val, universo)
19     mu_lgd = fuzzificar(lgd_val, universo)
20
21     # (2) Avalia o das regras:  $w = \min(\mu_{PD}, \mu_{LGD})$  para cada
        célula.
22     # A ativação de cada categoria de saída é o máximo das
        regras que a produzem.
23     ativacao = {cat: 0.0 for cat in CATEGORIAS}
24     for i, pd_cat in enumerate(CATEGORIAS):
25         for j, lgd_cat in enumerate(CATEGORIAS):
26             w = min(mu_pd[pd_cat], mu_lgd[lgd_cat])
27             out_cat = BASES_REGRAS[base][i][j]
28             if w > 1e-9:
29                 ativacao[out_cat] = max(ativacao[out_cat], w)
30
31     # (3) Agrega o: máximo ponto a ponto das MFs de saída
        truncadas.
32     agregada = np.zeros_like(universo)
33     for cat in CATEGORIAS:
34         truncada = np.minimum(ativacao[cat], mfs[cat])
35         agregada = np.maximum(agregada, truncada)
36
37     # (4) Defuzzifica o -> ver Se o C.5
38     return _defuzzificar(agregada, universo)

```

Fonte: Elaborado pelos autores (2026).

C.5. Método de Defuzzificação

A defuzzificação converte a função de pertinência agregada em um valor numérico único por meio do **método do centroide** (centro de gravidade), conforme descrito na Seção 2.4. O resultado corresponde à abscissa do centro de massa da área agregada e é, em seguida, reconvertido em categoria linguística (Código C.2).

Listing 5. Defuzzificação pelo método do centroide.

```

1 def _defuzzificar(agregada, universo=UNIVERSO):
2     """Etapa 4 (defuzzificação): centro de gravidade da função
   agregada.
3     IRC* = integral(y * mu(y) dy) / integral(mu(y) dy)."""
4     if agregada.sum() > 1e-12:
5         return float(fuzz.defuzz(universo, agregada, "centroid"))
6     return 0.0

```

Fonte: Elaborado pelos autores (2026).

Exemplo de execução: Para um ativo com $PD = 0,55$ e $LGD = 0,60$, o sistema dispara as regras das categorias intermediárias e retorna $IRC \approx 0,622$, classificado como **Alto** — coerente com a base de regras do especialista.

Listing 6. Exemplo de chamada do sistema de inferência.

```

1 >>> inferir_mamdani(0.55, 0.60, base="Especialista")
2 0.622
3 >>> irc_para_categoria(0.622)
4 'Alto'

```

Fonte: Elaborado pelos autores (2026).

C.6. Análise de Convergência entre as Fontes de Conhecimento

A comparação entre as três matrizes elicítadas (ChatGPT, Claude e Especialista — Tabelas 3, 4 e 5) é realizada célula a célula, classificando cada uma das 16 combinações em concordância total (as três fontes idênticas), concordância parcial (duas concordam) ou divergência total (três classificações distintas).

Listing 7. Análise de convergência entre as fontes de conhecimento.

```

1 def analise_convergencia():
2     """Compara as 3 matrizes célula a célula e contabiliza
3     concordância total, parcial e divergência total."""
4     fontes = ["ChatGPT", "Claude", "Especialista"]
5     total = parcial = divergente = 0
6     celulas = []
7     for i, pd_cat in enumerate(CATEGORIAS):
8         for j, lgd_cat in enumerate(CATEGORIAS):
9             vals = [BASES_REGRAS[f][i][j] for f in fontes]

```

```

10     distintos = set(vals)
11     if len(distintos) == 1:
12         total += 1
13     elif len(distintos) == 2:
14         parcial += 1
15         celulas.append((pd_cat, lgd_cat, vals))
16     else:
17         divergente += 1
18         celulas.append((pd_cat, lgd_cat, vals))
19     return {"concordancia_total": total,
20           "concordancia_parcial": parcial,
21           "divergencia_total": divergente,
22           "celulas_divergentes": celulas}

```

Fonte: Elaborado pelos autores (2026).

Nota de validação — consistência entre as Tabelas 6 e 7: A execução de `analise_convergencia()` sobre as três matrizes publicadas (Tabelas 3, 4 e 5) produz *12 combinações de concordância total (75%) e 4 de concordância parcial (25%)*, sem divergência total. As quatro combinações parciais identificadas pelo código são exatamente as quatro listadas na Tabela 7 (PD Baixo + LGD Crítico; PD Moderado + LGD Baixo; PD Moderado + LGD Crítico; PD Crítico + LGD Moderado). Recomenda-se, portanto, ajustar a Tabela 6, que indica 11 totais e 5 parciais, para 12 e 4, de modo a torná-la consistente com a Tabela 7 e com a contagem direta das matrizes.

C.7. Arquitetura da Aplicação Interativa

O sistema de inferência foi incorporado a uma aplicação interativa desenvolvida com o framework *Streamlit*. A aplicação é organizada de forma modular: um módulo central (`fuzzy_core.py`) contém o motor de inferência apresentado nas seções anteriores, e cada página corresponde a um aspecto da análise. A navegação é definida pelo dicionário apresentado a seguir.

Listing 8. Estrutura de navegação da aplicação Streamlit.

```

1 import streamlit as st
2 import fuzzy_core as fc
3
4 # Cada página é um módulo independente que importa o núcleo fuzzy.
5 PAGINAS = {
6     "Visão Geral & Tese": overview,
7     "1 Variáveis Fuzzy": fuzzy_variables, # MFs
8     "2 Bases de Regras": rule_bases, # 3 matrizes +
9     "3 Inferência Mamdani": mamdani, # inferência +
10    "4 Cúmulos (Dependência)": copulas, # Gaussiana vs
11    "5 Monte Carlo 2ª Ordem": monte_carlo, # incerteza
12    "6 Teoria da Possibilidade": possibility, # p-boxes

```

```

13     "7 Integra o no Portf lio": integration,          # IRC fuzzy +
14     c p u l a
15 }
16 escolha = st.sidebar.radio(" Navega o ", list(PAGINAS.keys()))
17 PAGINAS[escolha].render()

```

Fonte: Elaborado pelos autores (2026).

A página de inferência expõe controles para PD e LGD e apresenta, em tempo real, o IRC resultante, sua categoria, as regras ativadas e a superfície de decisão. O trecho abaixo ilustra a chamada ao núcleo e a exibição dos resultados.

Listing 9. Camada interativa da inferência Mamdani.

```

1 # Controles interativos (p gina "Infer ncia Mamdani")
2 pd_val = st.slider("PD Probabilidade de Default", 0.0, 1.0, 0.55,
3 0.01)
4
5 # Infer ncia com detalhamento das etapas
6 irc, det = fc.inferir_mamdani(pd_val, lgd_val, base="Especialista",
7 detalhar=True)
8
9 # Exibi o dos resultados
10 st.metric("IRC", f"{irc:.3f}")
11 st.metric("Categoria", det["categoria_irc"])
12 st.metric("Regras ativadas", len(det["regras_disparadas"]))

```

Fonte: Elaborado pelos autores (2026).

C.8. Módulos Complementares: Dependência e Propagação de Incerteza

Em linha com a discussão da Seção 4.4.3 — segundo a qual a lógica *fuzzy* (incerteza epistêmica dos parâmetros) e as cópulas (dependência entre *defaults*) são abordagens complementares — a aplicação inclui módulos que ilustram essa integração.

C.8.1. Cópula de Dependência (Gaussiana e t-Student)

A função abaixo gera amostras de uma cópula bivariada. A cópula *t-Student*, ao contrário da Gaussiana, apresenta dependência de cauda não nula, capturando a sincronização de *defaults* em cenários extremos discutida na Seção 2.1.

Listing 10. Amostragem de cópulas Gaussiana e t-Student.

```

1 from scipy import stats
2
3 def amostra_copula(tipo, rho, n, df=4, seed=0):

```

```

4      """Gera amostra 2D de uma c pula (Gaussiana ou t-Student)
5      com correla o rho."""
6      rng = np.random.default_rng(seed)
7      cov = np.array([[1.0, rho], [rho, 1.0]])
8      L   = np.linalg.cholesky(cov)
9      z    = rng.standard_normal((n, 2)) @ L.T
10     if tipo == "Gaussiana":
11         u = stats.norm.cdf(z)                # depend ncia de cauda nula
12     else:                                    # t-Student
13         g = rng.chisquare(df, n) / df
14         t = z / np.sqrt(g)[:, None]
15         u = stats.t.cdf(t, df)                # depend ncia de cauda > 0
16     return u

```

Fonte: Elaborado pelos autores (2026).

C.8.2. Simulação de Monte Carlo de Segunda Ordem

A simulação de segunda ordem separa explicitamente as duas naturezas de incerteza: um **laço externo** amostra os parâmetros PD e LGD de distribuições triangulares (incerteza epistêmica) e um **laço interno** simula os eventos de *default* via cópula (incerteza aleatória), produzindo uma distribuição de distribuições de perda.

Listing 11. Simulação de Monte Carlo de segunda ordem.

```

1 def mc_segunda_ordem(pd_tri, lgd_tri, rho, df,
2                     n_outer, n_inner, ead=1.0, seed=42):
3     """Monte Carlo de 2a ordem.
4     La o externo (epist mico): amostra par metros PD e LGD.
5     La o interno (aleat rio): simula defaults via c pula t."""
6     rng = np.random.default_rng(seed)
7     perdas = []
8     for _ in range(n_outer):
9         # Externo: sorteia os par metros (incerteza epist mica)
10        pd_param = rng.triangular(*pd_tri)
11        lgd_param = rng.triangular(*lgd_tri)
12
13        # Interno: simula os eventos (incerteza aleat ria)
14        cov = np.array([[1.0, rho], [rho, 1.0]])
15        L   = np.linalg.cholesky(cov)
16        z    = rng.standard_normal((n_inner, 2)) @ L.T
17        g    = rng.chisquare(df, n_inner) / df
18        u    = stats.t.cdf(z / np.sqrt(g)[:, None], df)
19        defaults = (u < pd_param).mean(axis=1)
20        perdas.append(defaults * lgd_param * ead)
21    return np.array(perdas) # matriz [n_outer x n_inner]

```

Fonte: Elaborado pelos autores (2026).

C.9. Correspondência entre Pacotes R e Python

A tabela a seguir relaciona os pacotes da literatura de referência (R) às bibliotecas Python efetivamente utilizadas na implementação, preservando a equivalência funcional entre as duas abordagens.

Tabela 16. Correspondência entre pacotes R e bibliotecas Python

Funcionalidade	Pacote R (referência)	Biblioteca Python (implementação)
Funções de pertinência	<i>sets, FuzzyNumbers</i>	<code>skfuzzy.trimf</code>
Fuzzificação (α -cut)	<i>FuzzyNumbers</i>	<code>skfuzzy.interp_membership</code>
Inferência Mamdani	<i>FRBS</i>	<code>skfuzzy + numpy</code> (min-máx)
Defuzzificação (centroide)	<i>FRBS, lfl</i>	<code>skfuzzy.defuzz</code>
Cópulas (Gaussiana / t)	<i>copula</i>	<code>scipy.stats + Cholesky</code>
Monte Carlo	<i>smc / base R</i>	<code>numpy.random</code>
Aplicação interativa	<i>shiny</i>	<code>streamlit</code>

Fonte: Elaborado pelos autores (2026).

C.10. Estrutura de Arquivos e Execução

O projeto é organizado nos seguintes arquivos principais. A aplicação é executada com o comando `streamlit run app.py` após a instalação das dependências listadas em `requirements.txt`.

Listing 12. Estrutura de arquivos do projeto e instruções de execução.

```

1 TE264/
2     app.py                                # navega o principal (Streamlit
3     )
4     fuzzy_core.py                        # motor Mamdani (Códigos C.1 C
5     .7)
6     theme.py                            # estilo visual e componentes
7     te264_historical_data.py            # parâmetros calibrados (PD, LGD
8     por setor)
9     requirements.txt
10    pages/
11        overview.py                      # visão geral e tese
12        fuzzy_variables.py               # funções de pertinência (C.3)
13        rule_bases.py                   # bases de regras e convergência
14        (C.6)
15        mamdani.py                       # inferência e superfície de
16        decis o
17        copulas.py                       # dependência (C.8.1)
18        monte_carlo.py                  # Monte Carlo de 2ª ordem (C.8.2)
19        possibility.py                   # teoria da possibilidade / p-
20        boxes
21        integration.py                   # IRC fuzzy + cópula no
22        portf lio

```

```
17 # Execu o :  
18 #   pip install -r requirements.txt  
19 #   streamlit run app.py
```

Fonte: Elaborado pelos autores (2026).

Os trechos apresentados neste apêndice reproduzem o núcleo da implementação. O código-fonte completo, incluindo as rotinas de visualização e a calibração dos parâmetros a partir de dados históricos, acompanha este trabalho como material suplementar.